

Anwendung von lokaler KI



Für alle die nicht da waren



Wie?

Über Backends (Ollama, llama.cpp, vllm)



Was?

Modelle (Qwen3.6-35B-A3B-FP8-Uncensored)



Wo?

Huggingface (Ollama.com, Github)



Warum?

Datenschutz und Kontrolle



<https://github.com/MrChaos1314/presentations#>

Ein Nachtrag zu Ollama

Freunde, lasst Freunde
nicht Ollama verwenden



Lizenzverstoß



Open Source ABER Closed Souce App



Schlechte Performance



Gelöstes Problem wiederbelebt



Schleierhafte Modellbenennung und Abhängigkeit



Kundenorientiert → Unternehmen & Cloud

[SR]

<https://sleepingrobots.com/dreams/stop-using-ollama/>

Was ist die Alternative?
Noch ein Lama!


```
# Option 2 - Build from source
# [Bei Windows WSL einrichten]
$ wsl --install
$ sudo apt update && sudo apt install git build-essential cmake
$ git clone https://github.com/ggerganov/llama.cpp
$ cd llama.cpp
$ cmake -B build
$ cmake --build build
$ ./build/bin/llama-server -m <MODEL> [-mmproj <VISION_MODEL>]
```





Einfach?

Geht so :/



Beispiel lm-studio

```
# Windows  
# Download von lm-studio  
# https://lmstudio.ai/download  
# Ausführen
```

```
# Linux  
# Download des AppImage  
# https://lmstudio.ai/download  
$ chmod +x lmstudio.AppImage  
$ ./lmstudio.AppImage
```

0
1
0
1
1
1
1
1
0
0
1
1
1
0
0

0
1
1
0
1
0
1
1
1
0
1
1
1
1
0

0
1
1
0
1
1
1



Performance zum Vergleich

VERWENDETER PROMPT

"Sollte man LLMs in der Cloud verwenden oder Lokal? Nenne Gründe dafür bzw. dagegen!"

Modell	Ollama	LM-Studio
Qwen3.6-27B-Q4_K_M	9 t/s	7 t/s
Gemma-4-e4b	76.30 t/s	76.45 t/s
gpt-oss-20b	96.83 t/s	129.07 t/s

Messgröße: Tokens pro Sekunde (t/s)

Anwendung bei Präsentationen

| KI fürs

• Brainstorming

• Aussehen

• Korrigieren

| Text selber schreiben

| Layout grob anordnen

| Seitenzahlen separat generieren

Anwendungsbereiche für VLMs

- Korrektur/Überprüfung von Grafiken
- Alternativtexte für Bilder (Barrierefreiheit)
- Schlüsselwortsuche
- Analog zu Digital

Anwendungsbereich von OCR

- Seit 19XX

- Text/Handschrift → Digitaler Text

- Vereinfachte Informationssuche

- Aufarbeitung für KI


Kleine Hinweise



Was man nicht machen sollte!



**Denken das wird schon passen
(und eine Präsentation gestalten)**



KERNEL PANIC!

Please reboot your computer.

Fatal exception in interrupt



Deine Hardware ist leider zu schlecht.
Tja. Das hast du davon.
Wie wäre es mit einer neuen Grafikkarte?

Lösche System... 20%



Weitere Informationen zu diesem Problem (und wie du dein Geld besser ausgeben kannst):
Scanne den QR-Code oder besuche <https://www.neue-grafikkarte.jetzt>

Wenn du den Support anrufst, gib bitte folgende Infos durch:
Stoppcode: ZU_WENIG_VRAM_WIEDER_VERSUCHS_DOCH

Kleine KI-Modelle



halluzinieren

ODER



**wiederholen
sich endlos**

Typische Grenzen kleiner lokaler Modelle

Ein wenig
Aufführung

• LIVE

Wie letztes Mal gilt
Viel Spaß beim Ausprobieren

Anwendung von lokaler KI



Ja nochmal KI – diesmal die Fortsetzung von letztem
Mal
Deshalb für die die nicht da waren

Für alle die nicht da waren



Wie?

Über Backends (Ollama, llama.cpp, vllm)



Was?

Modelle (Qwen3.6-35B-A3B-FP8-Uncensored)



Wo?

Huggingface (Ollama.com, Github)



Warum?

Datenschutz und Kontrolle



<https://github.com/MrChaos1314/presentations#>

2

Wie lassen wir KI laufen – über Backends
Womit laufen die KIs – mit Modellen wie bspw. XXX –
MTP - DSPARK – Instruct – GGUF – VL - OCR
Wo finden wir diese? – Huggingface – Ollama – Github
Was sind Gründe dafür – Datenschutz und Kontrolle
über Daten
Und weitere Punkte die wir in dieser Präsentation
durchgehen werden

Ein Nachtrag zu Ollama

Freunde, lasst Freunde
nicht Ollama verwenden



Lizenzverstoß



Open Source ABER Closed Souce App



Schlechte Performance



Gelöstes Problem wiederbelebt



Schleierhafte Modellbenennung und Abhängigkeit



Kundenorientiert → Unternehmen & Cloud



<https://sleepingrobots.com/dreams/stop-using-ollama/>

3

Ich hatte in der letzten Präsentation über Ollama gesprochen

Am Montag letzter Woche wurde mir den Artikel
Friends, let friends not use Ollama

MIT recht frei, aber nenne, wenn was davon

Preisen sich als open source und machen dann
Cloused Source Applikationen

Im vergleich zu bspw. Llama.cpp langsam

Llama.cpp hat sogar einen Standart gesetzt – GGUF,
eine File statt mehrern manchmal 50-100 Files, hat
man wiederbelebt

Auch recht undurchsichtig, was Modellbenennungen
angeht (Bspw. DeepSeek-R1 – Ohh doch Qwen)

→ Keine Freiheit neue Modelle zu testen, weil man auf
das wiederbelebte Problem an Format warten muss

Darstellung von Ollama als Kundenorientiert geht

Richtung Cloud und Unternehmen – Geld halt...



Was ist die Alternative? **Noch ein Lama!**

4

Was ist die Alternative? Richtig – noch ein Llama
Um genau zu sein llama.cpp
Schauen wir uns das an

5

Entweder wird haben glück und llama.cpp ist im
Packet-Manager vorhanden
Download – direkt verwenden
Oder
Man muss von Source das ganze bauen, jeweils für
seine bestimmte Grafikkarte
CUDA, ROCM, VULKAN, APPLES VERSION oder halt
(nicht empfehlenswert) CPU
Wsl installieren falls auf windows (dann bspw. Distro
nehmen wie arch, da es im Packet-Manager ist [Option
1 möglich])
Dann zum bauen des Source Codes benötigte
abhängigkeiten installieren
Repository clonen / downloaden
Ins verzeichnis und Bauen



Einfach?



Geht so :/

7

Es gibt auch eine andere Alternative

Beispiel lm-studio

```
# Windows  
# Download von lm-studio  
# https://lmstudio.ai/download  
# Ausführen
```

```
# Linux  
# Download des AppImage  
# https://lmstudio.ai/download  
$ chmod +x lmstudio.AppImage  
$ ./lmstudio.AppImage
```

0
1
0
1
1
1
1
1
0
0
1
1
1
1
0
0

0
1
1
1
0
1
1
1
1
0
1
1
1
1
0
1
1
0
1
1

0
1
1
1
0
1
1

8

Windows – Downloaden – Ausführen

Linux – Downloaden – Ausführbar machen –
Ausführen

Dann kann man auch direkt mal paar Modelle testen

Performance zum Vergleich

VERWENDETER PROMPT

"Sollte man LLMs in der Cloud verwenden oder Lokal? Nenne Gründe dafür bzw. dagegen!"

Modell	Ollama	LM-Studio
Qwen3.6-27B-Q4_K_M	9 t/s	7 t/s
Gemma-4-e4b	76.30 t/s	76.45 t/s
gpt-oss-20b	96.83 t/s	129.07 t/s

Messgröße: Tokens pro Sekunde (t/s)

Hier einmal ein Vergleich zu der Behauptung, dass Alternativen besser seien... soviel dazu

In dem Fall stimmt die Aussage je nach Modell, Llama.cpp ist teilweise nochmals schneller oder langsamer

Man erkennt auch gut, wo nur die Grafikkarte verwendet wurde und wo CPU "mitgeholfen" hat

Wie ist nun die Anwendung von Modellen

Anwendung bei Präsentationen

| KI fürs

- Brainstorming
- Aussehen
- Korrigieren

| Text selber schreiben

| Layout grob anordnen

| Seitenzahlen separat generieren

10

Wie wendet man KI am besten an?

Wie ich vorgegangen bin ist halt KI für brainstorming –
Optische Gestaltung und für Korrekturen

Dabei ist meine Erfahrung den Text und wo dieser
steht – sprich das Layout vorzugeben

Und empfehlenswert ist es Seitenzahlen separat zu
generieren, wenn sich positionen ändern – sonst
generiert man erstmal einen guten Teil neu

Anwendungsbereiche für VLMs

- Korrektur/Überprüfung von Grafiken
- Alternativtexte für Bilder (Barrierefreiheit)
- Schlüsselwortsuche
- Analog zu Digital

11

Wie können VLMs genutzt werden? (Vision Language Models)

Diese können helfen Grafiken zu Korrigieren und zu Prüfen

Alternativtexte zu generieren für eine barrierefreiere Anwendung

Schlüsselwortsuche von Bildern in Galerien und Archiven

Analog geschriebenes kann auch einfach in ein Digitales Format gebracht werden

Da kann man noch etwas genauer werden

Anwendungsbereich von OCR

- Seit 19XX

- Text/Handschrift → Digitaler Text

- Vereinfachte Informationssuche

- Aufarbeitung für KI

12

OCR modelle (Optical Character Recognition)
Gibt es eigentlich schon echt lange der Ansatz Text
iwie digital optisch zu erkennen
Aber VLMs? Dies sind spezielle VLMs die auf
Texterkennung und struktur Trainiert sind
Vorteile von denen gegenüber vlms sind, dass sie
genauer sind im durchgehen von Texten und
Handschrift
Erstellen daraus Digitalen Text
Vereinfacht suche durch Informationen durch große
Mengen an Bildern und Texten, wenn man was
bestimmtes sucht
OCR Modelle bereiten es teilweise KI gerecht auf –
Sehen wir auch gleich (hoffentlich)
Nun gut ... nun zu ein paar kleinen Hinweisen

Kleine Hinweise




Was man nicht machen sollte!



**Denken das wird schon passen
(und eine Präsentation gestalten)**

Ersteinmal denken, dass es schon passen wird beim Testen mit KI und dabei eine Präsentation zu erstellen



KERNEL PANIC!

Please reboot your computer.

Fatal exception in interrupt

Das macht den Linux Kernel Angst



Deine Hardware ist leider zu schlecht.
Tja. Das hast du davon.
Wie wäre es mit einer neuen Grafikkarte?

Lösche System... 20%



Weitere Informationen zu diesem Problem (und wie du dein Geld besser ausgeben kannst):
Scanne den QR-Code oder besuche <https://www.neue-grafikkarte.jetzt>

Wenn du den Support anrufst, gib bitte folgende Infos durch:
Stoppcode: ZU_WENIG_VRAM_WIEDER_VERSUCHS_DOCH

Das macht Windows sauer
ich übertreibe natürlich ein wenig, aber Vorsicht ist
besser als Nachsicht

Kleine KI-Modelle



halluzinieren

ODER



wiederholen
sich endlos

Typische Grenzen kleiner lokaler Modelle

16

Ein zweiter Punkt ist
Kleine Modelle machen viel Mist – besonders auf unter
Q4 Quantisierte Modelle
Diese Halluzinieren mal gerne
oder wieder holen sich mal gerne.
Genau
Was sie auch gerne tun ist zu halluzi...
Um das zu vermeiden kann man Temperatur und
Repetition-Penalty einstellen, dass das Model weniger
Entropie in der Wahl seiner Gewichte hat.
Und jetzt? Genug gelabbert und ein wenig live
Beispiele von dem, was ich erzählt habe

Ein wenig

• LIVE

Aufführung



Wie letztes Mal gilt
Viel Spaß beim Ausprobieren

